

Separação de Faixa de Bateria em Misturas Musicais por Meio de Máscaras Espectrais com U-Net

Philippe Amâncio Reis Caetano
Universidade de Brasília
Brasília, Brasil

Resumo—A separação de instrumentos individuais a partir de misturas musicais é uma tarefa desafiadora no processamento digital de áudio. Este trabalho apresenta uma implementação baseada em U-Net para estimar máscaras espectrais capazes de isolar a faixa de bateria de misturas musicais monofônicas. A entrada do modelo é formada por espectrogramas de magnitude normalizados, enquanto a saída corresponde a uma máscara espectral com valores entre zero e um. A abordagem combina perda de máscara ponderada, perda de magnitude e aumento de dados por mistura aleatória de stems. O modelo foi avaliado no conjunto de dados MUSDB18-HQ por meio da métrica SI-SDR. O melhor resultado alcançou SI-SDR de 3,72 dB, equivalente a uma melhoria de 7,41 dB sobre a linha de base que utiliza a própria mistura como estimativa da bateria. Apesar da melhoria objetiva, a avaliação auditiva ainda identificou vazamento de outros instrumentos, indicando limitações relacionadas à sobreposição espectral e ao uso da fase da mistura na reconstrução do sinal.

Index Terms—separação de fontes de áudio, U-Net, mascaramento espectral, bateria, aprendizado profundo, processamento digital de áudio

I. INTRODUÇÃO

A produção musical, a edição de áudio e a análise computacional de música podem exigir acesso a faixas individuais de instrumentos. Entretanto, grande parte das gravações musicais está disponível apenas como uma mistura final, na qual bateria, baixo, vocais e outros instrumentos ocupam simultaneamente o mesmo sinal de áudio.

A separação de fontes musicais busca estimar sinais individuais a partir dessa mistura. Neste trabalho, o objetivo é separar a bateria, por ser um instrumento de relevância rítmica e por possuir características espectrais e temporais que podem ser exploradas por modelos de aprendizado profundo.

Foi implementada uma arquitetura U-Net que recebe o espectrograma de magnitude de uma mistura musical e estima uma máscara espectral para a bateria. Essa máscara determina qual fração da magnitude de cada bin tempo-frequência deve ser preservada na estimativa da fonte alvo.

Além da configuração inicial baseada apenas em perda L1 da máscara, foi avaliada uma configuração com perda híbrida, máscara ponderada e aumento de dados por mistura aleatória. A estratégia de mistura aleatória cria combinações novas entre bateria, baixo, vocais e outros instrumentos, buscando ampliar a diversidade das misturas apresentadas durante o treinamento.

Os objetivos deste trabalho são:

- Implementar uma U-Net para estimativa de máscara espectral de bateria;
- Avaliar o desempenho do modelo por meio da métrica SI-SDR;
- Comparar a configuração inicial com a configuração que utiliza mistura aleatória e perda híbrida;
- Investigar limitações perceptuais, especialmente o vazamento de outros instrumentos no sinal separado.

II. METODOLOGIA

A. Conjunto de Dados

Foi utilizado o conjunto de dados MUSDB18-HQ, composto por 150 faixas musicais com stems separados. Cada faixa contém os seguintes arquivos:

- `mixture.wav`: mistura musical completa;
- `drums.wav`: faixa isolada de bateria;
- `bass.wav`: faixa isolada de baixo;
- `vocals.wav`: faixa isolada de vocais;
- `other.wav`: demais instrumentos.

O conjunto foi dividido em 100 faixas para treinamento e 50 faixas para teste.

B. Pré-processamento

Os áudios foram carregados com taxa de amostragem de 44,1 kHz e convertidos para mono. A representação tempo-frequência foi obtida por meio da Transformada de Fourier de Curto Tempo (*Short-Time Fourier Transform* – STFT).

Foram utilizados tamanho de janela de 2048 amostras e salto de 512 amostras. A STFT produz uma matriz complexa. A magnitude de cada posição tempo-frequência é obtida por:

$$|X(f, t)| = \sqrt{a^2 + b^2}, \quad (1)$$

em que $X(f, t)$ é o valor complexo da STFT no bin de frequência f e no quadro temporal t .

O último bin de frequência produzido pela STFT é removido, resultando em 1024 bins de frequência. Essa escolha mantém as dimensões compatíveis com as operações sucessivas de redução de resolução da U-Net.

A magnitude linear da mistura é convertida para decibéis:

$$X_{dB} = librosa.amplitude_to_db(|X|). \quad (2)$$

Em seguida, a representação em decibéis é normalizada para o intervalo $[0, 1]$:

$$X_{\text{norm}} = \text{clip} \left(\frac{X_{\text{dB}} + 80}{80}, 0, 1 \right). \quad (3)$$

Nota: na conversão para decibéis, a maior magnitude presente no espectrograma da mistura é usada como referência. Portanto, o bin de maior energia é representado por 0 dB. Valores situados mais de 80 dB abaixo dessa referência são limitados a -80 dB. Assim, a normalização mapeia o intervalo $[-80, 0]$ dB para $[0, 1]$.

A normalização é aplicada apenas à entrada da U-Net. A magnitude linear original $|X|$ é preservada para reconstruir a magnitude estimada da bateria.

A máscara alvo é calculada pela razão entre a magnitude da bateria e a magnitude da mistura:

$$M(f, t) = \text{clip} \left(\frac{|D(f, t)|}{|X(f, t)| + \varepsilon}, 0, 1 \right), \quad (4)$$

em que $|D(f, t)|$ é a magnitude da faixa de bateria, $|X(f, t)|$ é a magnitude da mistura e $\varepsilon = 10^{-8}$ evita divisão por zero.

Os exemplos de treinamento são divididos em segmentos de 256 quadros temporais, correspondentes a aproximadamente 3 segundos de áudio. Essa divisão permite processar faixas de duração completa em múltiplas etapas, sem que os espectrogramas completos e as ativações intermediárias da U-Net precisem ser armazenados simultaneamente na memória da GPU.

C. Arquitetura da Rede

A arquitetura utilizada consiste em uma U-Net com estrutura *encoder-decoder* e conexões de salto. A entrada possui o formato:

$$[B, 1, 1024, 256], \quad (5)$$

em que B representa o tamanho do lote, 1 representa o canal monofônico, 1024 representa os bins de frequência e 256 representa os quadros temporais.

O encoder possui quatro blocos de codificação. Cada bloco contém duas camadas convolucionais com kernels 3×3 , normalização de instância e ativação ReLU. Após cada bloco, uma operação de max pooling 2×2 reduz a resolução do mapa de características.

O número de canais aumenta progressivamente no encoder:

$$1 \rightarrow 16 \rightarrow 32 \rightarrow 64 \rightarrow 128. \quad (6)$$

No gargalo da U-Net, são utilizadas camadas convolucionais com 256 canais. O decoder realiza upsampling bilinear e concatena suas ativações às conexões de salto correspondentes do encoder, recuperando detalhes de frequência e tempo.

A camada final utiliza convolução 1×1 e função sigmoide:

$$\hat{M} = \sigma(\text{Conv}_{1 \times 1}(x)), \quad (7)$$

garantindo que os valores da máscara prevista $\hat{M}$ pertençam ao intervalo $[0, 1]$.

A normalização de instância é aplicada após cada convolução. Ela normaliza cada canal de cada exemplo independentemente nas dimensões de frequência e tempo, reduzindo a dependência da escala absoluta das ativações internas. Essa escolha é adequada ao tamanho de lote unitário, pois não depende de estatísticas agregadas de múltiplos exemplos.

O modelo possui aproximadamente 1,96 milhões de parâmetros treináveis.

D. Função de Perda

A configuração final utiliza uma função de perda híbrida formada por uma perda de máscara ponderada e uma perda de magnitude:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{mascara-ponderada}} + \lambda_{\text{mag}} \mathcal{L}_{\text{mag}}. \quad (8)$$

Foi utilizado $\lambda_{\text{mag}} = 0,1$. Esse valor reduz a contribuição da perda de magnitude na loss total, mantendo a estimativa da máscara espectral como objetivo principal do treinamento.

Sejam $\hat{M}_{b,f,t}$ e $M_{b,f,t}$ os valores da máscara estimada e da máscara alvo para o exemplo b , bin de frequência f e quadro temporal t . A máscara de validade $V_{b,f,t} \in \{0, 1\}$ vale 1 em regiões com áudio real e 0 em regiões inseridas por preenchimento (*padding*).

A perda de máscara ponderada é definida por:

$$\mathcal{L}_{\text{mascara-ponderada}} = \frac{\sum_{b,f,t} |\hat{M}_{b,f,t} - M_{b,f,t}| \cdot w_{b,f,t} \cdot V_{b,f,t}}{\sum_{b,f,t} V_{b,f,t}}. \quad (9)$$

O peso aplicado a cada bin é:

$$w_{b,f,t} = 1 + 2(1 - M_{b,f,t}). \quad (10)$$

Como a máscara alvo está no intervalo $[0, 1]$, o peso varia entre 1 e 3. Regiões com alta presença de bateria recebem peso próximo de 1, enquanto regiões sem bateria recebem peso próximo de 3. Dessa forma, erros em regiões onde não deveria haver bateria recebem maior penalidade, buscando reduzir vazamento de outros instrumentos.

A multiplicação por $V_{b,f,t}$ anula a contribuição de regiões inseridas por padding. A presença de $V_{b,f,t}$ no denominador garante que a loss seja a média calculada apenas sobre as posições correspondentes a áudio real.

A magnitude estimada da bateria é calculada a partir da máscara prevista e da magnitude linear original da mistura:

$$|\hat{D}_{b,f,t}| = \hat{M}_{b,f,t} \cdot |X_{b,f,t}|. \quad (11)$$

A perda de magnitude compara essa estimativa com a magnitude real da bateria:

$$\mathcal{L}_{\text{mag}} = \frac{\sum_{b,f,t} |\hat{M}_{b,f,t}| |X_{b,f,t}| - |D_{b,f,t}| \cdot V_{b,f,t}}{\sum_{b,f,t} V_{b,f,t}}. \quad (12)$$

A perda de máscara avalia diretamente a aproximação entre máscara prevista e máscara alvo. A perda de magnitude avalia se o efeito prático da máscara sobre a mistura produz uma magnitude de bateria próxima à referência.

E. Aumento de Dados por Mistura Aleatória

Durante o treinamento, foi utilizado aumento de dados por mistura aleatória (*random mix*). Para cada segmento, a faixa de bateria do exemplo original é mantida, enquanto as faixas de baixo, vocais e outros instrumentos são selecionadas de segmentos aleatórios do conjunto de treinamento.

A mistura sintética é dada por:

$$x_{\text{novo}} = d_{\text{original}} + b_{\text{aleatorio}} + v_{\text{aleatorio}} + o_{\text{aleatorio}}. \quad (13)$$

Após a criação da nova mistura, é aplicado um ganho aleatório comum à mistura e ao alvo de bateria, amostrado uniformemente no intervalo $[0, 7, 1, 3]$.

A estratégia é aplicada apenas ao conjunto de treinamento. O conjunto de teste permanece composto pelas misturas originais, permitindo uma avaliação reprodutível e diretamente comparável à linha de base.

F. Reconstrução do Áudio

A U-Net prevê uma máscara espectral, e não uma onda de áudio diretamente. A magnitude estimada da bateria, definida em (11), é combinada com a fase da mistura original:

$$\hat{D}(f, t) = |\hat{D}(f, t)|e^{j\angle X(f, t)}. \quad (14)$$

Por fim, aplica-se a Transformada Inversa de Fourier de Curto Tempo (*Inverse Short-Time Fourier Transform* – ISTFT) para obter o sinal de áudio estimado da bateria.

III. EXPERIMENTOS

A. Configuração Experimental

A avaliação foi realizada nas 50 faixas completas do conjunto de teste MUSDB18-HQ. A qualidade da separação foi medida pela razão sinal-distorção invariante à escala (*Scale-Invariant Signal-to-Distortion Ratio* – SI-SDR).

A linha de base utiliza a própria mistura musical como estimativa da bateria, sem aplicar qualquer método de separação. Dessa forma, ela representa o desempenho sem o uso da U-Net.

Foram comparadas três configurações experimentais:

- U-Net treinada por 10 épocas com perda L1 de máscara e misturas originais;
- U-Net treinada por 30 épocas com perda L1 de máscara e misturas originais;
- U-Net treinada por 30 épocas com perda híbrida, máscara ponderada e aumento de dados por mistura aleatória.

Nos dois experimentos iniciais, utilizou-se taxa de aprendizado de 5×10^{-5} , decaimento de peso de 10^{-3} , tamanho de lote igual a 1 e sem aumento de dados.

No experimento final, utilizou-se taxa de aprendizado inicial de 10^{-4} , decaimento de peso de 10^{-3} , tamanho de lote igual

a 1, mistura aleatória, máscara ponderada e perda híbrida com $\lambda_{\text{mag}} = 0, 1$. Um agendador ReduceLROnPlateau reduziu a taxa de aprendizado por um fator de 0,5 quando a loss de validação não apresentou melhora por duas épocas consecutivas. A taxa mínima de aprendizado foi 10^{-6} .

A loss de validação foi calculada sobre, no máximo, 500 batches do conjunto de teste, percorridos em ordem fixa. A seleção do melhor checkpoint foi realizada pelo maior valor de SI-SDR calculado sobre as 50 faixas completas do conjunto de teste.

B. Métrica SI-SDR

Sejam s o sinal de referência de bateria e $\hat{s}$ o sinal estimado. Antes do cálculo, ambos são centralizados pela remoção de suas médias.

A estimativa é projetada sobre o sinal de referência por meio do fator:

$$\alpha = \frac{\langle \hat{s}, s \rangle}{\|s\|^2}. \quad (15)$$

O componente alinhado à referência é:

$$s_{\text{alvo}} = \alpha s, \quad (16)$$

enquanto o componente residual é:

$$e_{\text{rudo}} = \hat{s} - s_{\text{alvo}}. \quad (17)$$

A SI-SDR é dada por:

$$\text{SI-SDR} = 10 \log_{10} \left(\frac{\|s_{\text{alvo}}\|^2}{\|e_{\text{rudo}}\|^2} \right). \quad (18)$$

Valores maiores indicam maior similaridade entre a estimativa e a referência. Como a métrica é invariante à escala, diferenças globais de ganho entre os sinais não são penalizadas diretamente.

A melhoria em relação à linha de base, denominada SI-SDRi, é calculada por:

$$\text{SI-SDRi} = \text{SI-SDR}_{\text{modelo}} - \text{SI-SDR}_{\text{baseline}}. \quad (19)$$

C. Resultados

Tabela I
RESULTADOS NO CONJUNTO DE TESTE MUSDB18-HQ

Método	Épocas	SI-SDR	SI-SDRi
Linha de base: mistura	–	-3,69 dB	0,00 dB
U-Net, loss L1	10	-1,95 dB	+1,74 dB
U-Net, loss L1	30	-0,21 dB	+3,48 dB
U-Net + random mix + loss híbrida	30	3,72 dB	+7,41 dB

A Tabela I apresenta os resultados obtidos. A linha de base, na qual a mistura foi utilizada diretamente como estimativa da bateria, apresentou SI-SDR de -3,69 dB.

A U-Net treinada com perda L1 de máscara atingiu -1,95 dB após 10 épocas, o que representa uma melhoria de 1,74 dB sobre a linha de base. Após 30 épocas com a

mesma configuração, o resultado melhorou para -0,21 dB, correspondendo a ganho de 3,48 dB.

A configuração com random mix, máscara ponderada e perda híbrida obteve o melhor resultado. O maior SI-SDR foi 3,72 dB, obtido na época 26 de um treinamento de 30 épocas. Esse valor corresponde a uma melhoria de 7,41 dB em relação à linha de base.

A última época apresentou SI-SDR de 3,49 dB. Portanto, o checkpoint da época 26 foi selecionado para representar o melhor desempenho do experimento.

D. Análise Perceptual

A configuração final apresentou a maior melhoria objetiva na métrica SI-SDR. Entretanto, a avaliação auditiva deve complementar a análise numérica, pois o aumento da métrica não garante isolamento perceptualmente completo.

Ainda pode ocorrer vazamento de baixo, vocais ou outros instrumentos, principalmente em regiões de sobreposição tempo-frequência. Esse efeito ocorre quando fontes distintas compartilham energia em frequências próximas no mesmo instante temporal, dificultando a atribuição da magnitude a uma única fonte.

Além disso, a reconstrução utiliza a fase da mistura original. Embora essa escolha permita reconstruir o áudio a partir da magnitude estimada, ela pode preservar componentes temporais associados a fontes interferentes. Assim, a melhoria de SI-SDR indica redução objetiva de distorção em relação à referência, mas não implica ausência completa de vazamento ou artefatos perceptíveis.

IV. DISCUSSÃO

Os resultados indicam que o treinamento adicional da U-Net com perda L1 foi capaz de reduzir parte da interferência presente na mistura. O aumento de -1,95 dB para -0,21 dB ao passar de 10 para 30 épocas mostra que o modelo ainda se beneficiava de maior tempo de treinamento.

A configuração final combinou três alterações: perda híbrida, máscara ponderada e mistura aleatória. Essa configuração alcançou SI-SDR de 3,72 dB, superando a configuração L1 de 30 épocas em 3,93 dB e superando a linha de base em 7,41 dB.

A máscara ponderada busca reduzir vazamento ao penalizar mais fortemente predições não nulas em regiões onde a bateria está ausente ou possui baixa presença. A perda de magnitude complementa esse objetivo ao comparar a magnitude obtida após aplicar a máscara com a magnitude real da bateria.

A mistura aleatória aumenta a diversidade das combinações de fontes durante o treinamento. Como a bateria é combinada com baixo, vocais e outros instrumentos oriundos de segmentos diferentes, o modelo deixa de depender apenas das relações específicas de uma mixagem original. Essa maior diversidade pode contribuir para a melhora observada no conjunto de teste.

Entretanto, a influência individual de cada componente não foi isolada neste experimento. Como perda híbrida, máscara ponderada e random mix foram introduzidos conjuntamente, não é possível atribuir quantitativamente a melhora de 3,93 dB

a apenas uma dessas alterações. Experimentos de ablação são necessários para medir separadamente a contribuição de cada elemento.

V. LIMITAÇÕES E TRABALHOS FUTUROS

A principal limitação da abordagem é a utilização da fase da mistura durante a reconstrução. A U-Net estima apenas uma máscara de magnitude e não aprende uma representação explícita da fase da bateria. Isso pode limitar a fidelidade de transientes e contribuir para artefatos ou vazamento perceptível.

Como trabalhos futuros, podem ser realizados experimentos de ablação com as seguintes configurações:

- Apenas random mix;
- Apenas máscara ponderada;
- Apenas perda híbrida;
- Random mix com perda L1;
- Perda híbrida sem random mix;
- Máscara ponderada sem perda de magnitude.

Esses experimentos permitiriam identificar o impacto individual de cada escolha metodológica.

Outra possibilidade é investigar estimativa de fase por máscaras complexas ou modelos que operem diretamente no domínio temporal. Esses métodos poderiam reduzir limitações causadas pela reutilização da fase da mistura.

Por fim, pretende-se utilizar o áudio de bateria separado como entrada de um sistema de transcrição automática. Esse sistema poderá identificar eventos como bumbo, caixa, chimbal, tons e pratos, convertendo-os para MIDI ou mapas de notas compatíveis com aplicações de jogos de ritmo, como o Paradiddle VR.

VI. CONCLUSÃO

Este trabalho apresentou uma implementação de U-Net para separação de bateria em misturas musicais, utilizando máscaras espectrais aplicadas à magnitude da mistura. A arquitetura foi treinada e avaliada no conjunto MUSDB18-HQ por meio da métrica SI-SDR.

A configuração inicial baseada em perda L1 alcançou SI-SDR de -0,21 dB após 30 épocas, correspondendo a uma melhoria de 3,48 dB sobre a linha de base. A configuração que incorporou aumento de dados por mistura aleatória, máscara ponderada e perda híbrida alcançou SI-SDR de 3,72 dB na época 26, representando SI-SDR_i de 7,41 dB.

Os resultados demonstram que a configuração final reduziu a distorção em relação à linha de base e superou os experimentos iniciais. No entanto, a existência de vazamento perceptível mostra que a separação ainda apresenta limitações. Estudos futuros devem avaliar a contribuição individual das alterações propostas e explorar estratégias conscientes de fase e transcrição automática de bateria.

AGRADECIMENTOS

O autor agradece à Universidade de Brasília pelo contexto acadêmico de desenvolvimento deste trabalho e aos autores e mantenedores do conjunto de dados MUSDB18-HQ.

REFERÊNCIAS

- [1] E. Vincent, S. Watanabe, A. A. Nugraha, J. Barker e R. Lebarbenchaut, “The MUSDB18 corpus for music separation,” 2018. Disponível em: <https://sigsep.github.io/datasets/musdb.html>.
- [2] O. Ronneberger, P. Fischer e T. Brox, “U-Net: Convolutional networks for biomedical image segmentation,” em *Proceedings of the International Conference on Medical Image Computing and Computer-Assisted Intervention*, 2015, pp. 234–241.
- [3] J. Le Roux, S. Wisdom, H. Erdogan e J. R. Hershey, “SDR – half-baked or well done?” em *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing*, 2019, pp. 626–630.